Built with PriorLabs-TabPFN

House Prices 最终方案

线上成绩与数据

0.11212

Kaggle log-RMSE，越低越好。由用户于 2026-10-16 反馈；未通过 Kaggle 接口独立读取。

较上一版 v5 的 0.11595 降低 0.00383，约 3.30%；较首版 0.11969 降低约 6.32%。用户已选择保留本版，停止继续优化。

最终采用 v6：将已有传统模型集成与两种 TabPFN 特征表示组合，以不同预测方向的互补性降低误差。模型和提交文件保持 v6.0.0 原样；v6.1.0 补充实测成绩、报告和分享说明。

数据来源与任务

项目	本次使用的数据
比赛	Kaggle House Prices: Advanced Regression Techniques
官方数据	用户下载的官方 ZIP；train.csv、test.csv、data_description.txt、sample_submission.csv
规模	训练 1,460 行；测试 1,459 行；79 个解释变量
目标与标识	SalePrice 为美元房价；以 ln(SalePrice) 建模；Id 只用于对应提交行，不作特征
缺失值	保留字符串 None 的类别含义；NA 读作缺失；模型内预处理只使用当前训练部分

已经提交的版本成绩

版本	v1	v2	v3	v4	v5	v6
线上 log-RMSE	0.11969	0.11741	0.11770	0.11679	0.11595	0.11212

最终三路融合

1/3 · v5	1/3 · physical	1/3 · quality
既有 ElasticNet、CatBoost、SVR 集成	住宅结构特征 TabPFN 16 个内部成员	质量类别表示 TabPFN 4 个内部成员

log(price) = (z_v5 + z_physical + z_quality) / 3

z 表示各路的对数房价预测，最后用 exp 转回房价。等价于三路价格的几何平均；16 与 4 是内部集成规模，不是两路在最终结果中的权重。

方法与实验依据

两种表示如何互补

physical：原始变量上增加总面积、完工面积、浴室数、房龄、车库龄、门廊面积、质量等级与面积交互等，共 112 列。将 MSSubClass 当类别，排除 Id 与 SalePrice。

quality：保留原始 79 个变量，将 OverallQual、OverallCond 显式改成类别字符串，保留其他字段。它与结构特征路线形成不同的预测视角。

模型：使用官方公开 TabPFN v2 回归权重，固定来源 revision 与 SHA-256。安装包版本为 tabpfn 9.2.0，模型权重版本为 v2，两者含义不同。v6 的训练上下文使用全部 1,460 行；没有额外微调预训练权重。

v5：复用已有 ElasticNet、CatBoost 与 SVR 的集成方向。其 SVR 增量在大面积区域按训练面积分位数逐渐减弱，完整历史代码和预测一并保存。

五组配置的受控比较

本轮候选，均与 v5 各半融合	全体	普通房屋	Normal
原始特征 / 4 成员	0.115493	0.104159	0.084423
住宅结构特征 / 4 成员	0.114577	0.103989	0.084223
住宅结构特征 / 16 成员	0.114594	0.103996	0.084197
训练侧删除两套极端房屋 / 4 成员	0.115488	0.104153	0.084423
质量字段改为类别 / 4 成员	0.115046	0.103650	0.084322

上表固定各半融合，便于比较特征和训练处理。删除极端训练样本几乎没有额外收益，未用于最终模型。最终再将两个互补 TabPFN 方向与 v5 各取 1/3。

最终配方的同折对比

同折本地 log-RMSE	v5 参考	最终 v6
全体 1,460 行	0.119686	0.113673
排除两套极端房屋，仅诊断	0.105870	0.103518
Normal 成交，1,198 行	0.086587	0.083906

验证使用全体训练数据的 KFold 5 折（shuffle=True，seed=5509），与核验过的 v5 缓存严格匹配；未删除任何验证行。所有预处理在各折训练部分拟合。

这些房屋和拆分已用于历史筛选，因此本地数值具有方案选择偏差，不是全新独立验证，也不能与线上分数直接混作同一个指标。

结果判断与复现

为什么保留三路等权

除 0%/25%/50%/75%/100% 的粗权重外，增加自然的三路等权方案。三路等权在普通房屋与 Normal 成交上都优于 TabPFN 总权重 50% 和 75% 的方案。75% 的总体本地分数更低，但相对 50% 的新增收益约 96.9% 来自两套极端房屋，因此未选作最终提交。

相对原 v5，分别去掉每组改善最大的五套房屋后，普通房屋和 Normal 组仍有正净收益。不过调权增量仍集中在少数房屋，不能据此保证每一组或新数据都会改善。线上实测 0.11212 是本次最终采用的依据，之后没有继续据此调参。

复现与文件入口

位置	用途
submission_v6.csv	最终已提交文件，1,459 行
src/ 与 scripts/	特征、模型、实验与预测入口
experiments/v6/fit_context.joblib	两路 TabPFN 的训练上下文与配置
experiments/v6/pretrained/	44 MB 公开权重、来源与许可
submission_v5.csv	v6 复用的历史融合预测
experiments/v6/online_result.json	用户反馈的线上成绩和文件对应关系
docs/SHARING_GUIDE.md	接收者上手、平台与分享说明

已有 macOS ARM64 环境时，运行：

```
sh scripts/run_tabpfn.sh scripts/predict_v6.py
sh scripts/run_tabpfn.sh scripts/report_v6.py
```

使用 Python 3.12。原环境锁为 requirements-tabpfn.lock.txt；非 Mac ARM64 的安装参考 requirements-tabpfn-portable.txt。原锁文件仍须保留，预测脚本会核对其哈希。非 MPS 环境当前会选 CPU，尚未做跨平台运行验证。

已核验全部 1,459 行、Id 顺序与正数房价。两模型全量重载后，对相同预测方向换成最终权重进行核验，最大对数差为 1.59e-08。GPU 浮点误差并非逐位完全一致。

提交文件 SHA-256：
cf1c335f3a580accd45457e8bc4247185bd97b9aef656a6adf5ecc8cb288b63f

来源与版本

比赛与数据：https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques

TabPFN 官方实现：https://github.com/PriorLabs/TabPFN

官方 v2 回归权重与许可：https://huggingface.co/Prior-Labs/TabPFN-v2-reg

项目最终文档版本：https://github.com/WANGDAKEKE/kaggle-houseprice/tree/v6.1.0

Built with PriorLabs-TabPFN。公开权重的 LICENSE.txt 随代码包保留。模型与提交冻结在 v6.0.0；v6.1.0 仅补充线上结果、最终报告和分享材料。